Restauration, Analyse et Refonte de l’Architecture de Données

REALISE PAR : ABDULKADIR GUVEN (DATA ENGINEER)

POUR : NOSCITES

DATE : NOVEMBRE 2025

Contexte du projet

La Situation

- Activité : Surveillance de l'impact des locations courte durée (Airbnb).
- Périmètre : Paris & Lyon.
- Enjeu : JO 2024.

L'Incident

- Crash Critique de la base de données unique (Paris).
- Perte de disponibilité.
- Risque de sécurité.

Ma Mission

1. Restaurer & Analyser (Import, Qualité, KPIs)
2. Pérenniser l'Architecture (NoSQL, Réplication, Sharding)

Importation des données

- Importation depuis Mongo Compass
- Le type “string” a été forcé pour les colonnes à types mixtes
- Le type “long” a été choisi pour l’identifiant

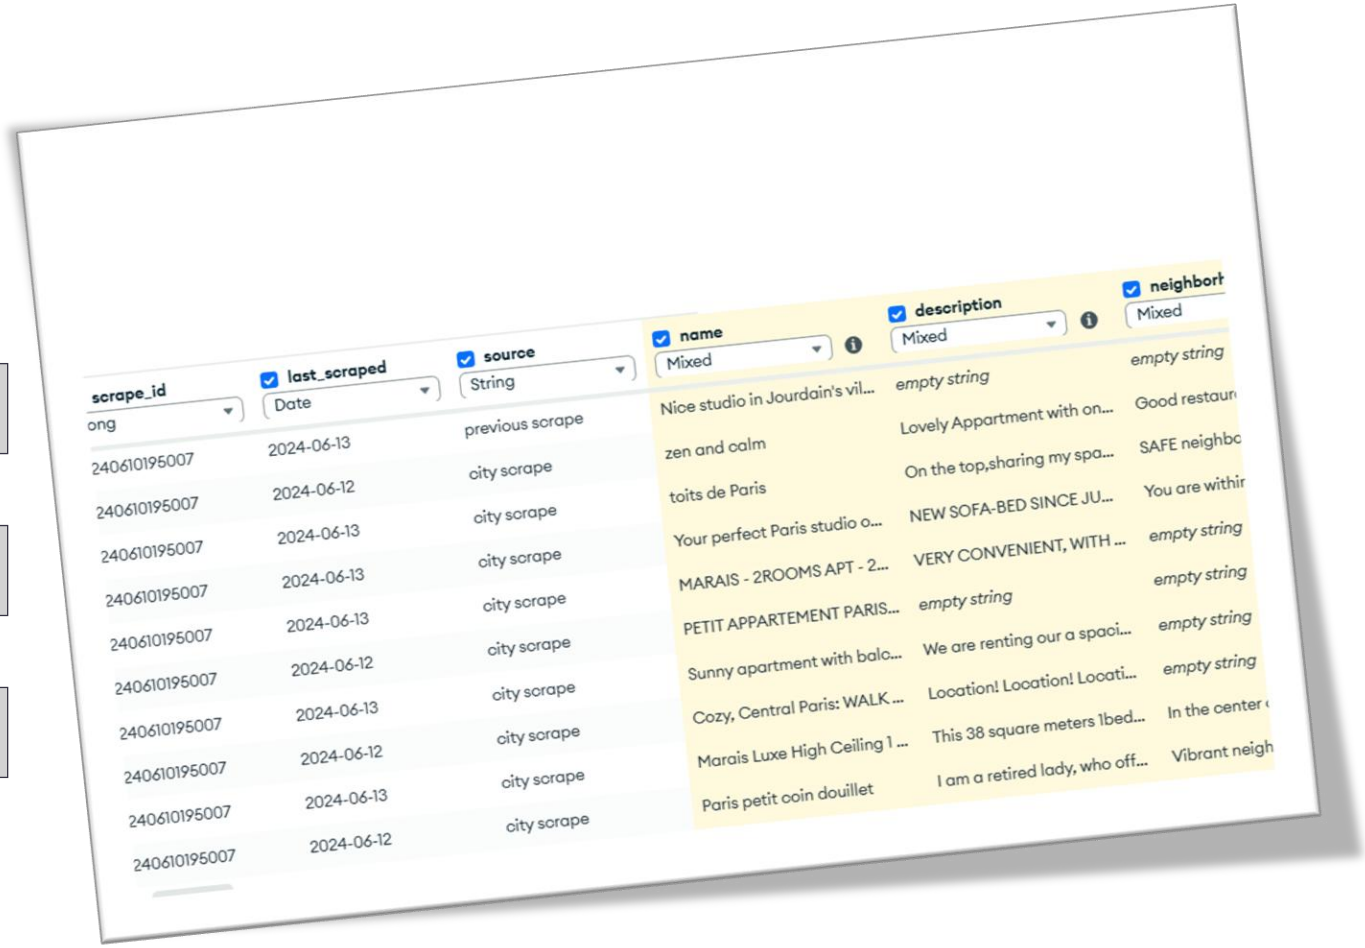

scrape_id	last_scraped	source	name	description	neighborh
ong	Date	String	Mixed	Mixed	Mixed
240610195007	2024-06-13	previous scrape	Nice studio in Jourdain's vil...	empty string	empty string
240610195007	2024-06-12	city scrape	zen and calm	Lovely Appartment with on...	Good restaur
240610195007	2024-06-13	city scrape	toits de Paris	On the top,sharing my spa...	SAFE neighbo
240610195007	2024-06-13	city scrape	Your perfect Paris studio o...	NEW SOFA-BED SINCE JU...	You are withir
240610195007	2024-06-13	city scrape	MARAIS - 2ROOMS APT - 2...	VERY CONVENIENT, WITH ...	empty string
240610195007	2024-06-12	city scrape	PETIT APPARTEMENT PARIS...	empty string	empty string
240610195007	2024-06-13	city scrape	Sunny apartment with balc...	We are renting our a spaci...	empty string
240610195007	2024-06-12	city scrape	Cozy, Central Paris: WALK ...	Location! Location! Locati...	empty string
240610195007	2024-06-13	city scrape	Marais Luxe High Ceiling 1 ...	This 38 square meters 1bed...	In the center
240610195007	2024-06-12	city scrape	Paris petit coin douillet	I am a retired lady, who off...	Vibrant neigh

Premier document importé

Extrait de la collection Paris


```
},
"id": 80260,
"listing_url": "https://www.airbnb.com/rooms/80260",
"scrape_id": 20240610195007,
"last_scraped": {
  "$date": "2024-06-13T00:00:00Z"
},
"source": "previous scrape",
"name": "Nice studio in Jourdain's village",
"picture_url": "https://a0.muscache.com/pictures/716553/6c14f251_original.jpg",
"host_id": 333548,
"host_url": "https://www.airbnb.com/users/show/333548",
"host_name": "Charlotte",
"host_since": { "$date": "2011-01-03T00:00:00Z"},
"host_location": "Paris, France",
"host_about": "My name is Charlotte, I'm 26 and I study cinema production. I'll be gone the whole year to study in Grenoble and
"host_response_time": "N/A",
"host_response_rate": "N/A",
"host_acceptance_rate": "N/A",
"host_is_superhost": false,
"host_thumbnail_url": "https://a0.muscache.com/im/users/333548/profile_pic/1350320876/original.jpg?aki_policy=profile_small",
"host_picture_url": "https://a0.muscache.com/im/users/333548/profile_pic/1350320876/original.jpg?aki_policy=profile_x_medium",
"host_neighbourhood": "Buttes-Chaumont - Belleville",
"host_listings_count": 1,
"host_total_listings_count": 1,
"host_verifications": "['email', 'phone']",
"host_has_profile_pic": true,
"host_identity_verified": true,
"neighbourhood_cleansed": "Ménilmontant",
"latitude": 48.87131,
"longitude": 2.38848,
"property_type": "Entire rental unit",
"room_type": "Entire home/apt",
"accommodates": 3,
"bathrooms_text": "1 bath",
"bedrooms": 1,
"amenities": [ "Hangers", "Essentials", "Wifi", "Heating"],
"minimum_nights": 2,
"maximum_nights": 730,
"minimum_minimum_nights": 2
```

La richesse d'un document NoSQL

Exemples concrets issus de la base Paris

Champs concernés	Observations	Avantages vs. SQL
amenities et *host_verifications*	Stockés sous forme de tableaux	Pas besoin de jointure
calendar_updated et *neighbourhood_group_cleansed*	Schéma flexible : seules les données existantes sont stockées, sans contrainte de colonne.	Pas de colonnes pleines de NULL.
has_availability, *instant_bookable* etc	MongoDB a converti automatiquement les chaînes ‘t’/‘f’ en booléen.	Importation flexible et intelligente. Évite le prétraitement des données souvent nécessaire en SQL.
Structure globale du document	Données issues du web déjà en JSON, directement compatibles avec MongoDB.	MongoDB parle nativement JSON et JS, idéal pour les données web.

Analyse des types de données

Champs	Constat	Action
price	Présence du symbole ‘$’ a empêché la conversion automatique pendant l’importation	Nettoyer, convertir en *Double* et renommer le champ en *price_usd* pour expliciter la devise.
host_acceptance_rate	Pourcentage stocké sous forme de texte à cause de symbole `%`.	Nettoyer, convertir en *Double* et renommer
host_response_rate	Pourcentage stocké sous forme de texte à cause de symbole `%`.	Nettoyer, convertir en *Double* et renommer.
host_verifications	Tableau stocké sous forme de texte.	Convertir en *Array*.

Premières requêtes d'exploration

Nombre total de documents

- `db.paris_listings.countDocuments()`
- **95 885** annonces au total

Logements disponibles

- `db.paris_listings.countDocuments({has_availability: true})`
- **91 202** annonces disponibles (soit **95.12**%)

Répartition par type de chambre

Combien d'annonces y a-t-il par type de location

```
db.paris_listings.aggregate([
  { $group:
    {
        _id: "$room_type",
        count: { $sum: 1 } }
    },
  { $sort: { count: -1 } }
]);
```

Type de chambre	Nombre d'annonces
Entire home/apt	85 733
Private room	8 975
Hotel room	776
Shared room	401

Nota : *Une granularité plus fine (appartement, maison, loft...) est également disponible via le champ property_type.*

Top 5 des Annonces (par Nombre d'Évaluations)

```
db.paris_listings.find(
  {},
  { name: 1, number_of_reviews: 1, _id: 0 }
)
.sort({ number_of_reviews: -1 })
.limit(5);
```

Sweet & cosy room next to Canal Saint Martin 💗

- 3067

Double/Twin Room, close to Opera and the Louvre with breakfast included

- 2620

Bed in Dorm of 8 Beds \"The Big One\" in Paris

- 2294

Comfortable bed in shared rooms of 8 in Paris 12e

- 2105

Nice Room for 2 people

- 2048

Hôtes et Annonces : Chiffres Clés

Quel est le nombre de locations réservables instantanément ? Cela représente quelle proportion des annonces ?

```
// 3 Quel est le nombre total d'hôtes différents ?
const nb_hosts = db.paris_listings.distinct("host_id").length;


// 4 Quel est le nombre de locations réservables instantanément ?
// Cela représente quelle proportion des annonces ?
const nb_bookable_listings = db.paris_listings.countDocuments({
                                instant_bookable: true
                            });

const pct_bookable = (nb_bookable_listings / nb_listings) *100 ;
```

Hôtes uniques

- 71 979

Réservations instantanées

- 22 094

Part des annonces (%)

- 23,04

Identification des Hôtes Professionnels

```
// -----------------------------------------------------
// 5️⃣ Est-ce que des hôtes ont plus de 100 annonces sur les plateformes ?
// Et si oui qui sont-ils ?
// Cela représente quel pourcentage des hôtes ?
// -----------------------------------------------------
const heavy_host_list = db.paris_listings.aggregate([
    {
        $group: {
            _id: {
                host_id: "$host_id",
                host_name: "$host_name"
            },
            total: {$sum: 1}}
    },

    {
        $match: { total: { $gt: 100 } }
    },

    { $sort: {total: -1}},
]).toArray();

const pct_heavy_host = (heavy_host_list.length / nb_hosts) * 100 ;
```

host_id	host_name	total
314994947	Blueground	730
33889201	Veeve	497
50502817	Pierre De WeHost	426
50978178	Sébastien	307
26981054	Cédric De ClickYourFlat	274
…	…	…
528015349	Checkmyguest	189
506389460	Check My Guest	109
512746089	Checkmyguest	104
374552379	Checkmyguest	104
499962530	Check My Guest	103
21630783	Pierre	102

Pourcentage des hôtes pro. : 0,03%

Proportion de Super-Hôtes

```
// ---------------------------------------------------
// 6️⃣ Nombre total de superhôtes
// ---------------------------------------------------
const nb_superhosts = db.paris_listings
                        .distinct("host_id", { host_is_superhost: true })
                        .length;
const pct_superhosts = (nb_superhosts / nb_hosts) * 100;
```

Super-hôtes uniques

- 10 027

Part des hôtes (%)

- 13,93

Analyses Statistiques Avancées avec Polars

Polars

Profil des Annonces et des Hôtes

Taux de Réservation Mensuel Par Type de Logement	
Type de Logement	Taux de Réservation
Entire home/apt	71,29 %
Private room	70,15 %
Shared room	60,82 %
Hotel room	51,24 %

Nombre d'Avis (Médiane) par Catégorie d'Hôte	
Catégorie d'Hôte	Nb. Avis (médian)
Global	4,0
Hôte standard	2,0
Hôte non classé	12,5
Super hôte	24,0

🕵️ Les logements entiers et les chambres privées constituent le cœur du marché parisien (>70% de réservation)

🕵️ Le statut ***Super-hôte*** est un indicateur de performance clé, avec une activité **12 fois supérieure** à celle d'un hôte standard.

Analyse Géographique : Offre vs. Demande

Quartiers avec le Plus Grand Nombre d'Annonces (Top 10)

Quartier	Nb. Annonces
Buttes-Montmartre	10478
Popincourt	8354
Vaugirard	7710
Batignolles-Monceau	6792
Entrepôt	6498
Passy	6344
Buttes-Chaumont	5412
Ménilmontant	5230
Opéra	4545
Reuilly	3972

Taux de Réservation par Quartier

Quartier	Taux de réservation	Nb. Annonces
Ménilmontant	75.39	5230
Popincourt	74.79	8354
Entrepôt	74.72	6498
Buttes-Chaumont	74.17	5412
...	...	...
Palais-Bourbon	68.97	2722
Bourse	68.63	3031
Luxembourg	66.48	2689
Élysée	62.32	2870
Passy	62.24	6344

Pipeline d'Intégration Business Intelligence

Installer de BI Connector

Installer la MongoDB BI Connector ODBC Driver

Dans ODBC Data Source, ajouter un DSN

Lancer BI Connecter

Ajouter des vues dans MongoDB

Sélectionner la source ODBC depuis PowerBI

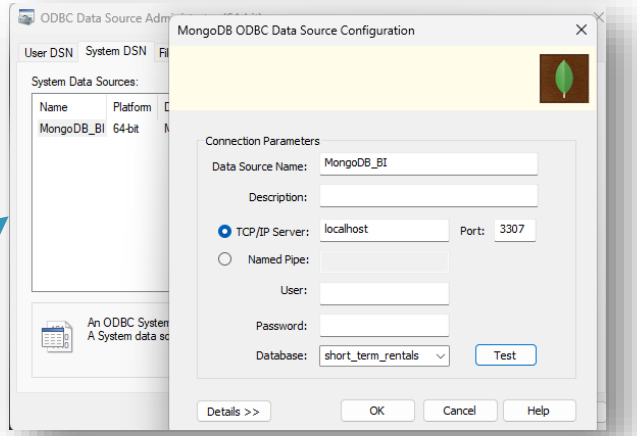


```
# --- Start-MongoBI.ps1 ---
# This script starts the MongoDB BI Connector (mongosqld)
# to make your MongoDB database accessible to Power BI via ODBC.

$mongoUri = "mongodb://localhost:27100"
$connectorPath = "C:\Program Files\MongoDB\Connector for BI\2.14\bin\mongosqld.exe"

Write-Host "------------------------------------------------"
Write-Host "Starting the MongoDB BI Connector"
Write-Host "ℹ️ MongoDB Target: $mongoUri"
Write-Host "------------------------------------------------"

Start-Process -FilePath $connectorPath -ArgumentList "--mongo-uri", $mongoUri -NoNewWindow
Write-Host "✅ The BI Connector is running on port 3307. You can now launch Power BI."
```

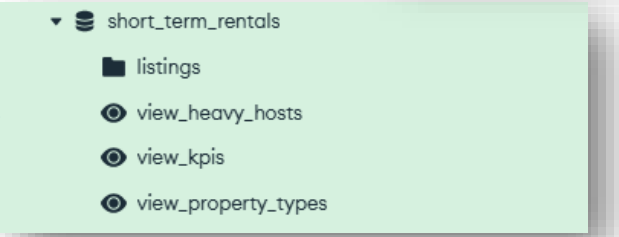

Restitution Analytique : Tableau de Bord

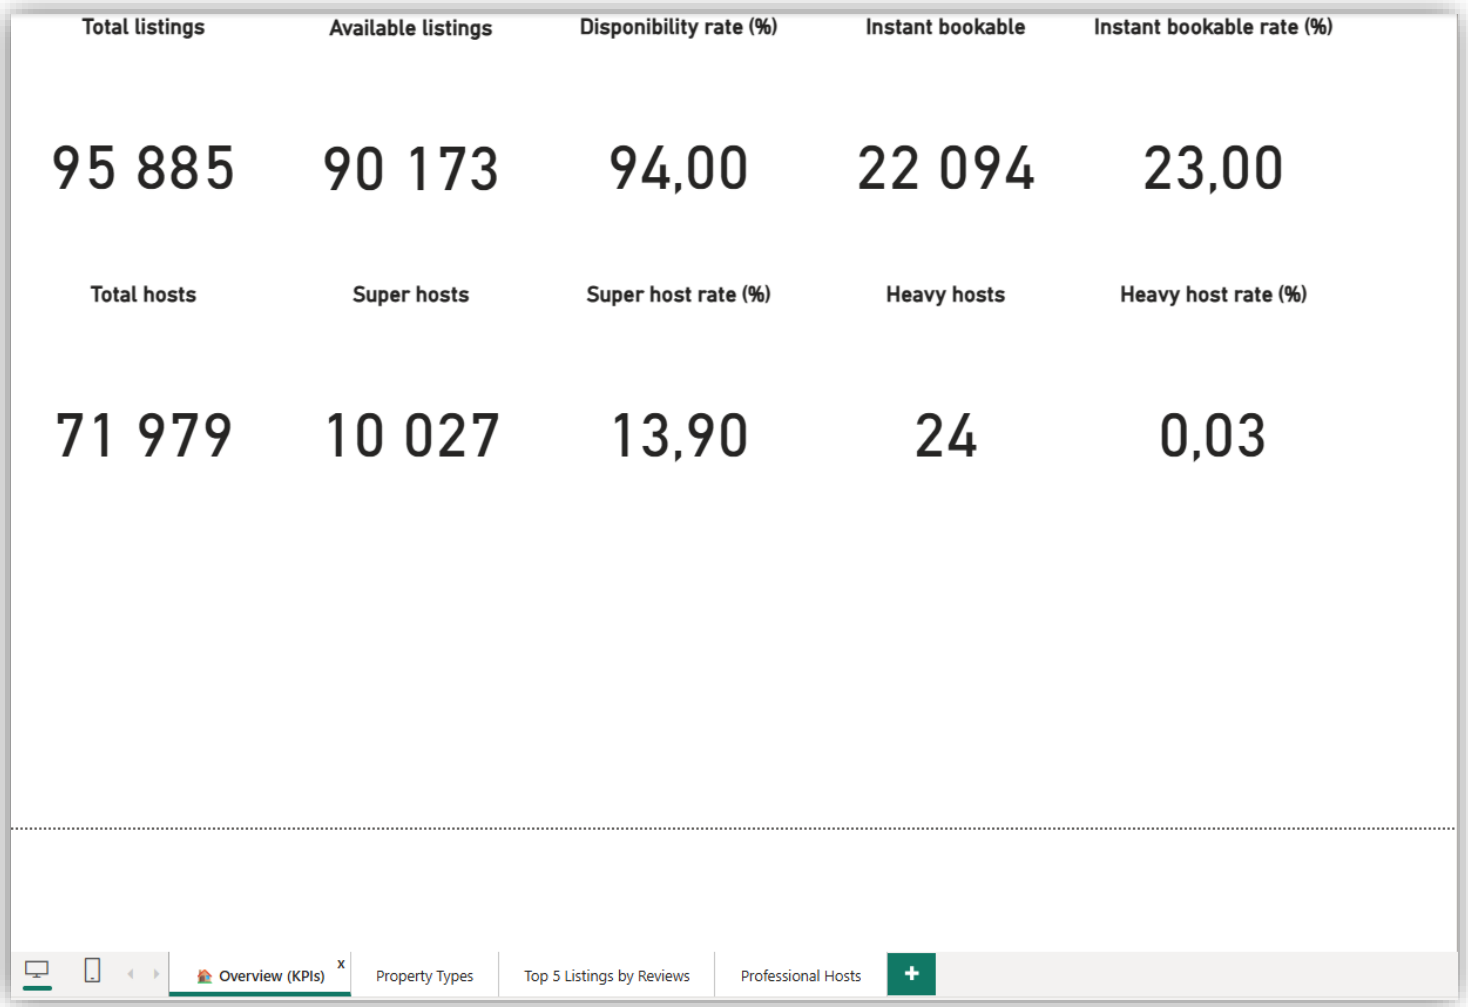

Sécurisation et Haute Disponibilité (HA)

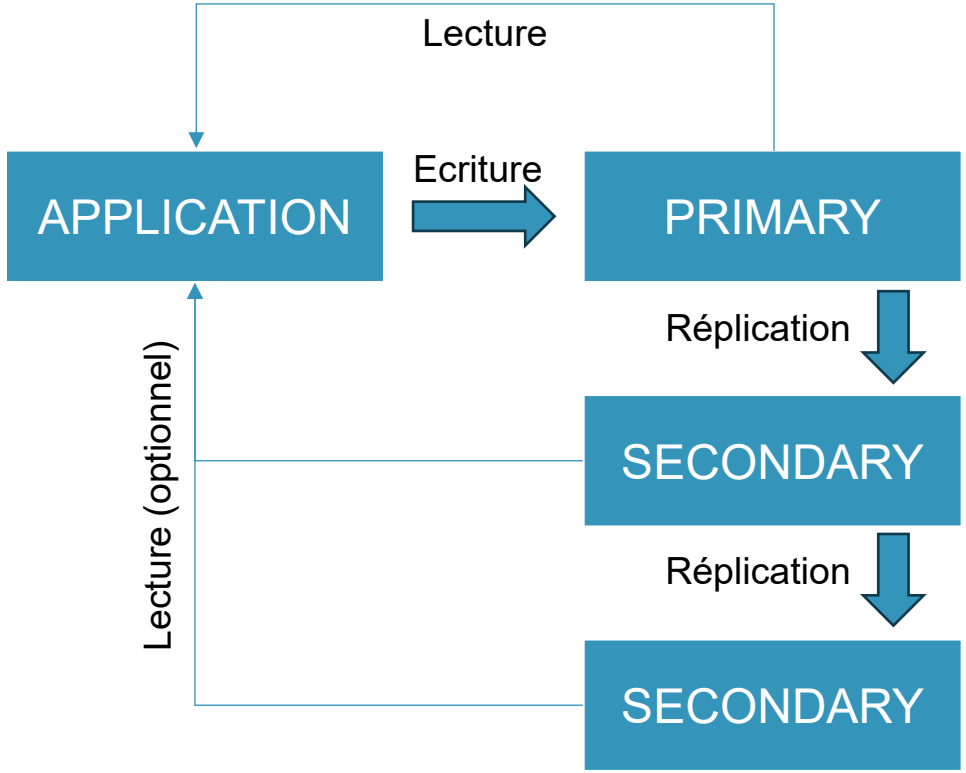

Problème:

- Un seul serveur => SPOF

Solution:

- Replicaset à 3 nœuds (Architecture PSS)

Avantages :

- Evite les incidents comme celui de Paris

Inconvénients:

- Coût supérieur à une architecture PSA.

Architecture Cible : Cluster Distribué Multi-Sites

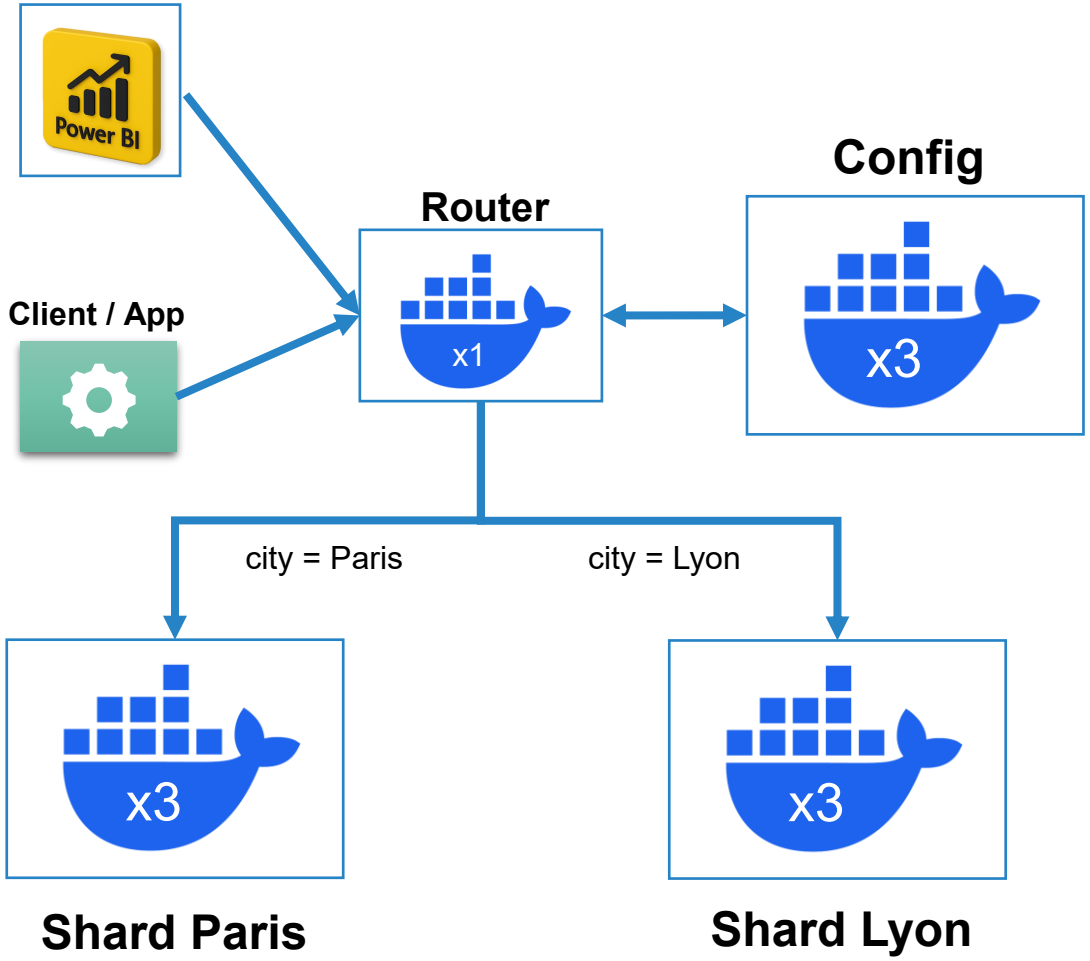

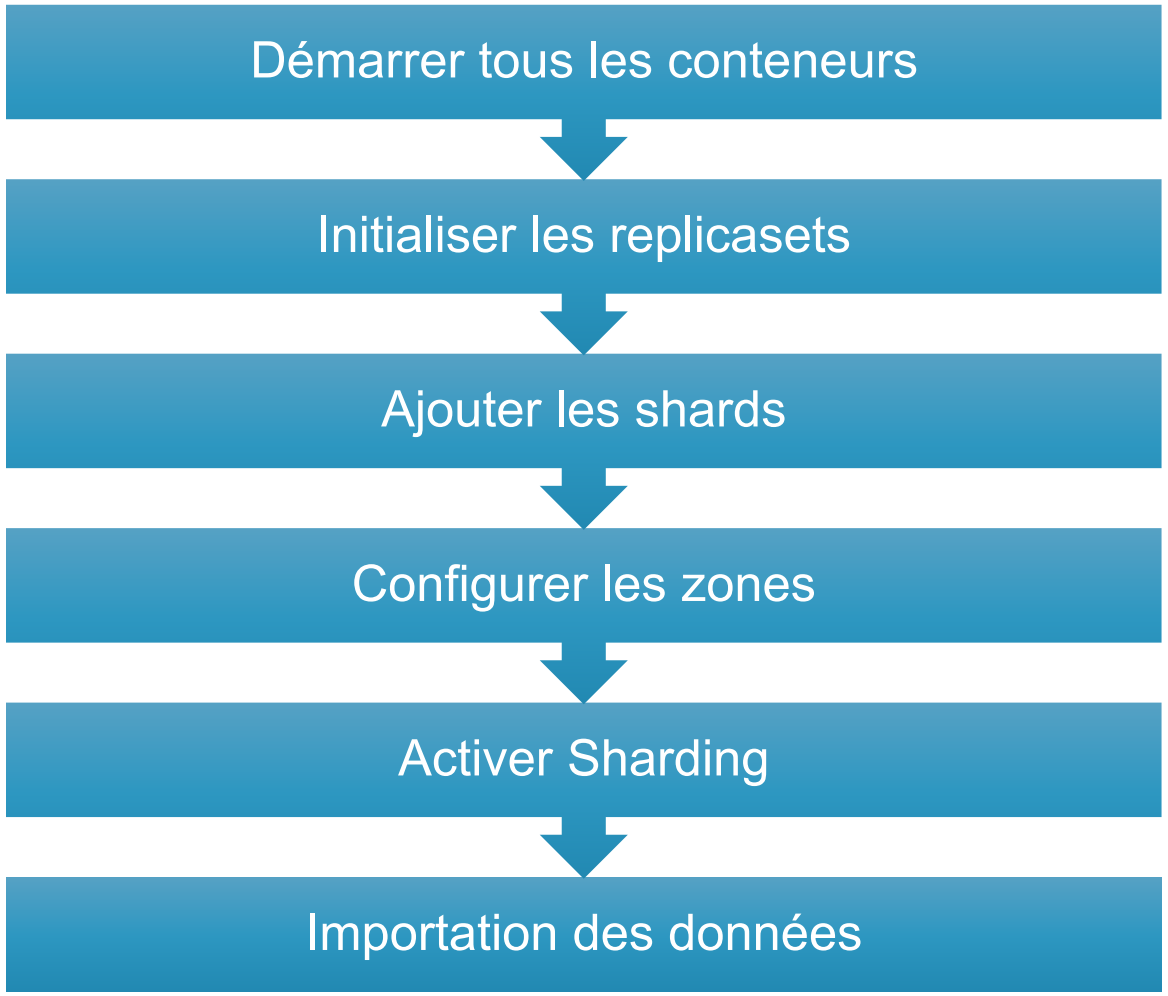

Architecture Cible : Stratégie de Distribution

Aspect	Choix Technique
Clé de Sharding	Champ city
Type de Sharding	Tag-Aware Sharding (Zones)
Optimisation	Requêtes ciblées
Résultat	Isolation totale


```
{
  "Shard noscites_shard1_rs at noscites_shard1_rs/noscites-shard1-1:27017,noscites-shard1-2:27017,no
    "data": "313.86MiB",
    "docs": 95885,
    "chunks": 2,
    "estimated data per chunk": "156.93MiB",
    "estimated docs per chunk": 47942
  },
  "Shard noscites_shard2_rs at noscites_shard2_rs/noscites-shard2-1:27017,noscites-shard2-2:27017,no
    "data": "32.05MiB",
    "docs": 9973,
    "chunks": 3,
    "estimated data per chunk": "10.68MiB",
    "estimated docs per chunk": 3324
  },
  "Totals": {
    "data": "345.92MiB",
    "docs": 105858,
    "chunks": 5,
    "Shard noscites_shard1_rs": [
      "90.73 % data",
      "90.57 % docs in cluster",
      "3KiB avg obj size on shard"
    ],
    "Shard noscites_shard2_rs": [
      "9.26 % data",
      "9.42 % docs in cluster",
      "3KiB avg obj size on shard"
    ]
  }
}
```


Distribution des données

Bilan de l'Intervention et Perspectives

Objectifs Atteints

✅ Restauration et Fiabilisation : Données de Paris et Lyon unifiées

✅ Pilotage Décisionnel : Mise à disposition d'indicateurs clés (KPIs) via Power BI

✅ Infrastructure Pérenne : Déploiement d'une architecture distribuée garantissant Haute Disponibilité (Replica Set) et Performance Locale (Sharding).

Recommandations & Roadmap

🔒 **Sécurisation des accès :** Mise en place de mots de passe et de connexions sécurisées (TLS) pour la production.

🔄 Automatisation : Mettre en place un pipeline ETL automatique pour l'ingestion mensuelle des nouveaux fichiers CSV.

🧹 **Qualité des Données :** Industrialiser le nettoyage des autres champs identifiés lors de l'audit (prix, pourcentages, etc.).